

单位代码: 10293 密 级: _____

南京邮电大学

硕士 学位 论 文



论文题目: 基于矩阵分解和深度学习的弱光照图像增强
方法研究

学 号 1020051427

姓 名 李丰耀

导 师 胡长晖

学 科 专 业 控制科学与工程

研 究 方 向 图像处理

申 请 学 位 类 别 工学硕士

论 文 提 交 日 期 _____

Research on low light image enhancement based on matrix decomposition and deep learning

Thesis Submitted to Nanjing University of Posts and
Telecommunications for the Degree of
Master of Science in Engineering



By
Feng-yao Li
Supervisor: Prof. Chang-hui Hu

April 2023

南京邮电大学学位论文原创性声明

本人声明所呈交的学位论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得南京邮电大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

本人学位论文及涉及相关资料若有不实，愿意承担一切相关的法律责任。

研究生学号：_____ 研究生签名：_____ 日期：_____

南京邮电大学学位论文使用授权声明

本人承诺所呈交的学位论文不涉及任何国家秘密，本人及导师为本论文的涉密责任并列第一责任人。

本人授权南京邮电大学可以保留并向国家有关部门或机构送交论文的复印件和电子文档；允许论文被查阅和借阅；可以将学位论文的全部或部分内容编入有关数据库进行检索；可以采用影印、缩印或扫描等复制手段保存、汇编本学位论文。本文电子文档的内容和纸质论文的内容相一致。论文的公布（包括刊登）授权南京邮电大学研究生院办理。

非国家秘密类涉密学位论文在解密后适用本授权书。

研究生签名：_____ 导师签名：_____ 日期：_____

摘要

Lorem ipsum dolor sit amet, consectetur adipisicing elit,sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.

关键词：学位论文，**LATEX** 模板

Abstract

This paper is a help documentation for the L^AT_EX class ucasthesis, which is a thesis template for the University of Chinese Academy of Sciences. The main content is about how to use the ucasthesis, as well as how to write thesis efficiently by using L^AT_EX.

Keywords: University of Chinese Academy of Sciences (UCAS), Thesis, L^AT_EX Template

目录

第一章 绪论 ······	1
1.1 课题研究背景和意义 ······	1
1.2 弱光照图像增强研究现状 ······	1
1.2.1 基于数学模型的弱光照图像增强方法 ······	2
1.2.2 基于深度学习的弱光照图像增强方法 ······	3
1.3 弱光照图像增强技术目前存在的问题 ······	4
1.4 本文主要研究工作概述 ······	4
第二章 相关背景知识介绍 ······	6
第三章 基于 QRCP-DWT 的弱光照图像增强算法 ······	7
3.1 引言 ······	7
3.2 基于 QRCP-DWT 的弱光照图像增强算法 ······	7
3.3 实验 ······	10
第四章 基于奇异值参数的弱光照图像增强算法 ······	11
4.1 引言 ······	11
4.2 基于奇异值参数的弱光照图像增强算法 ······	11
4.2.1 奇异值增强模型 ······	11
4.3 实验 ······	14
4.3.1 数据库 ······	14
4.3.2 评价指标和数据库设置 ······	14
4.3.3 对比方法 ······	15
4.3.4 实验结果 ······	15
第五章 基于亮度先验的弱光照图像增强算法 ······	17
5.1 引言 ······	17
5.2 基于亮度先验的弱光照图像增强算法 ······	17
5.2.1 QRCP-DWT 和 SVE 算法的局限性分析 ······	17
5.2.2 网络实现与损失函数 ······	18
5.2.3 重增强网络与一般有监督网络的比较 ······	19
5.3 实验 ······	19
第六章 总结与展望 ······	20
参考文献 ······	21
附录 1 攻读硕士学位期间撰写的论文 ······	22
附录 2 攻读硕士学位期间申请的专利 ······	23
附录 3 攻读硕士学位期间参加的科研项目 ······	24
致谢 ······	25

第一章 绪论

1.1 课题研究背景和意义

在夜晚条件下，监控设备成像光照不足，导致弱光照图像的产生。弱光照图像中，由于对比度低，有效信息被隐藏，人眼难以直接获取信息，不仅如此，弱光照图像也不利于图像检测和识别。因此，如何对弱光照图像进行增强，来得到光照良好的图像，逐渐成为近年来的研究热点。

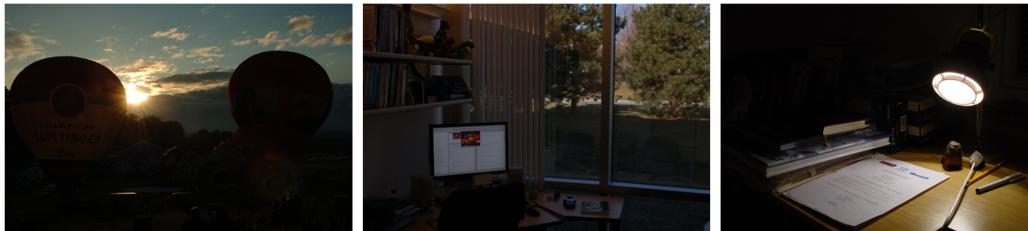


图 1.1 不同场景下的弱光照图像

在夜晚采集的图像由于夜间照明的特殊性，光源来源复杂，强弱不一，使得夜晚环境或者光线亮度不足（如黯淡月光、星光、烛光等），拍摄的图像亮度值极低，可见度和对比度严重下降，并伴随着大量的随机噪声；或者光照分布不均匀（局部有光源照射，如车灯、路灯、日光灯等），使部分区域照明充足而其他区域亮度极低影响这些区域的细节可见度和局部对比度，并在较暗区域产生比其他区域更复杂的噪声分布；抑或因为光源（如钠灯、霓虹灯等）产生的照明光本身并非白色，影响场景内物体表面的反射光的颜色，使拍摄得到的图像出现色彩偏差。

基于 RGB 的弱光照图像增强算法需要处理三个颜色通道，而基于 HSV 的弱光照图像增强算法只需要处理饱和度通道和亮度通道，降低了算法的运行时间。另外，基于 HSV 的弱光照图像增强算法可以使增强结果具有对比度高，颜色信息丰富的优点。现有的弱光照增强方法往往没有考虑到极弱光照下真实场景图像的情况，增强后的图像存在亮度不足，噪声放大和信息丢失。因此，有必要针对极弱光照图像增强研究一种更加有效的方法。

1.2 弱光照图像增强研究现状

弱光照图像整体亮度偏暗，对比度低，大部分噪声集中在黑暗区域，局部细节容易丢失，不利于案件侦察、医学影像诊断、目标追踪、视频后期处理等。为了解决弱光照图像给计算机视觉任务带来的问题，国内外学者对弱光照图像增强做出了大量的研究，弱光照增强方法主要可分为基于数学模型的方法和基于深度学习的方法。

1.2.1 基于数学模型的弱光照图像增强方法

基于数学模型的弱光照图像增强方法主要包括基于基于伽马校正的方法、基于直方图均衡化的方法以及基于 Retinex 的方法。伽马函数 [1] (Gamma function) 应用范围较广，合理搭配其他图像处理方法可以提升图像增强效果。伽马校正 [2] (Gamma Correction, GC) 以非线性方式对图像进行处理，虽然伽马校正可以提高图像弱光照区域亮度，但是它不考虑某个像素与其相邻像素之间的关系，暗区细节信息易丢失。直方图均衡化 [3] (Histogram Equalization, HE) 利用灰度的统计特征，将原图像的灰度分布从较为集中的区间映射到整个灰度区域均匀分布，从而达到图像增强的效果。全局直方图均衡化基于弱光照图像的全局信息，未考虑到图像纹理等细节信息，容易使物体轮廓部分的细节丢失，还会出现增强过度现象。相反，局部直方图均衡化重点考虑图像的纹理细节，对图像局部区域亮度提升效果好，但易忽视图像的整体性，导致增强后的弱光照图像毫无层次感，影响视觉效果。

基于 Retinex 的弱光照图像增强方法。Retinex[4] 不同于直方图均衡化，Retinex 专注于局部增强，这在一定程度上解决了全局增强算法对图像局部区域亮度增强不足的问题，可以在动态范围压缩、边缘增强和颜色恒常三个方面达到平衡，因此能对不同类型的图像进行自适应增强。随之，研究者们在此理论上提出大量改进的算法。Jobson[5] 等人提出了单尺度 Retinex 理论 (Single-scale Retinex, SSR)，其采用低通滤波器估算图像光照分量，尽管其原理简单，节省时间成本，但易因尺度参数选择困难而导致图像色彩失真。对此，基于 SSR 基础上，多尺度 Retinex 理论 [6] (Multi-scale Retinex, MSR) 诞生了，MSR 在增强过程中可以保持图像的本质特征，但受限于产生最终结果的方式，增强出来的图像会在某些区域增强过度，会出现图像纹理不清晰，高频区域突出不明显等情况。Rahman[7] 等人在 MSR 基础上提出带有色彩恢复因子的多尺度 Retinex 理论 (Multi-scale Retinex with Color Restoration, MSRCR)，增加对颜色的操作得以保持图像色彩，令图像趋向自然化，但图像颜色整体还是会相对泛白，有很大的改进空间。Guo[8] 等人基于 Retinex 理论，通过估计光照分量，提高图像亮度，这样做可以缩小解空间和减少计算量。但正因其依赖于光照分量，在极低照度环境下的图像会因光照度不够导致增强结果过暗，对于弱光照图像的亮度过大的背景区域又会出现增强过度的现象。Wang[9] 等人使用亮度滤波去分解图像，从而得到光照图和反射图，增强光照的同时尝试在细节和自然度之间达到平衡。Fu[10] 等人利用一种加权变化的模型来估计光照图和反射率。Li[11] 等人第一次尝试预测图像的噪声，同时对结构反射图和分段平滑光照图进行了估计，该算法可以使用在含噪声的低照度环境下，还适用于遥感图像增强、水下图像增强等，但对细节的处理仍需加强。Ren[12] 等人基于 Retinex 模型，针对图像分解后反射率存在的噪声的问题，提出了一种序列评估模型，分别估计光照图和反射率，最后将估计后的反射率和伽马校正后的光照图合并得到增强后的图像。作者没有依次迭代更新照明图和反射图得到最优解，是

考虑到光照图基本上是光滑的，而密集噪声几乎都留在了反射图中，因此轮流更新光照图和反射率时会对光照图带来噪声并对细节信息造成破坏。

1.2.2 基于深度学习的弱光照图像增强方法

基于深度学习 [13] (Deep Learning, DL) 的弱光照图像增强方法不依赖于人工经验值，而依靠数据集训练而得。近年来研究学者们陆续提出基于深度学习的方法来解决弱光照图像增强问题。基于深度学习的弱光照图像增强方法主要包括基于监督学习的方法和基于无监督学习的方法。监督学习方法是基于建立大量亮暗图像对之间的映射。Shen[14] 等人引入卷积神经网络 [15](Convolutional Neural Network, CNN)，将 MSR 原理应用到神经网络中，仿照 MSR 流程提出了一个新的网络 MSR-net，学习弱光照图像与之对应的高光图像之间的映射关系，但其抗噪性能差，对细节的保留程度低，还常出现增强过度的情况。Chen[16] 等人受到 Retinex 理论的启发，在不考虑反射率和光照分解的地而真实性的情况下，以数据驱动的方式将观测图像分解为反射图和光照图，鉴于分解得到的反射图与高光图像的反射图类似，只对分解得到的光照图像进行增强，并采用 BM3D[17] 进行去噪，该方法在增强过程中能很好地保持图像色彩，但在噪声和细节处理方面仍有改进之处。Wang[18] 等人提出了一种全局光照感知和细节保持网络 (GLADNET)。GLADNET 对低光输入进行全局光照估计，然后在估计的指导下调整光照，并与原始输入进行拼接补充细节，该方法增强后的质量较之前的方法有了很大的提升，但在增强过程中易出现颜色和背景等畸变的情况，针对处在不同场景中的图像的鲁棒性也相对较差。Chen[19] 等人关注极端低光条件和短时间曝光条件下的图像成像系统，在极低照度环境下拍摄了大量配对的数据集，提出用卷积神经网络完成 RAW 图像到 RGB 图像之间的映射，该方法表现出惊人的效果，但是也因为该方法需要对每一种相机的传感器单独训练网络，会导致泛化能力差。与此同时，其数据集不包含人像或动态目标等，不便处理 HDR 色调映射。Zhang[20] 等人提出了一种点燃黑暗的算法 (KinD)，将弱光照图像及其对应的高光图像分解为反射图和光照图，分别对分解得到的光照图和反射图进行增强操作，这种方法对于极低照度下的弱光照图像是非常有效的，但缺点是增强后的图像色彩容易失真，在细节恢复方面仍有很大的提升空间。

无监督学习方法是在非成对数据集上训练的，通过自监督训练措施和无监督损失函数达到训练目的。Yang[21] 等人借助全监督学习去获得重建图像的细节和特征，由于直接通过无监督学习来学习低照度图像和正常光照图像之间的关系很难获得具有高质量的图像，作者引入了一组高质量图像来辅助无监督训练，通过生成式对抗网络学习高质量图片的质量信息，增强后的图像在恢复出图像细节的同时提高了图像质量。从整体来看是一种基于半监督学习的低照度图像增强方法。Guo 等人提出了一种新的零参考深度曲线估计方法 (Zero-DCE)，提

出一种无参考网络，相较于有参考网络，无参考网络能有效避免过拟合问题，模型的泛化能力也相对更好。该方法将增强光照作为利用深度网络进行图像特定曲线估计的任务，它通过一组精心制定的非参考损失函数来实现图像增强。Zero-DCE 的吸引力在于它在训练过程中不需要任何配对或未配对的数据，然而，它在处理噪声方面还有提升空间，有时还会出现颜色扭曲。基于生成式对抗网络 [23] 的 EnlightenGAN[24]，引入不成对的学习来训练光照增强模型，摆脱了对成对的数据集的依赖，能够构建一个低光照图像和正常光照图像之间的非成对映射关系。

1.3 弱光照图像增强技术目前存在的问题

基于数学模型的弱光照图像增强方法处理速度快，算法简单，但对于复杂照度下的弱光照图像，譬如极低照度下的夜晚图像抑或光照严重不足的图像，要去除隐藏在黑暗中噪声的同时还要保留物体原本物理属性，这是具有一定难度的。

1.4 本文主要研究工作概述

本课题主要围绕以下两个方面问题展开研究：1) 针对经典 HSV 模型可扩展性差的问题，研究如何在直接投影面上计算饱和度和色调，为提出更好的色调和饱和度定义方式创造条件。2) 针对弱光照增强出现的过饱和现象，导致增强图像的色彩过于艳丽的问题，研究如何抑制弱光照图像的饱和度通道，使增强后的图像色彩信息更真实，同时针对极弱光照图像增强难度大，增强后亮度不足导致失真的问题，研究如何构建亮度增强模型，使得极弱光照图像增强后亮度得到较大提升。

主要研究内容如下：

(1) 基于直接投影的 HSV 彩色模型经典 HSV 模型 [25] 在作颜色立方体垂直于亮度轴的平面上的投影六边形时，设定立方体中的线段与投影六边形中对应线段长度相等，即对直接投影六边形作线性缩放，获得间接投影六边形，根据线段长度计算饱和度和色调。这种做法使得饱和度和色调的定义方式唯一，不利于模型的可扩展性。针对经典 HSV 模型可扩展性不足的问题，本课题首先在色彩空间中获得真实投影圆面，研究基于正弦值的色调模型，同时研究基于真实投影圆面的饱和度模型，并保持其亮度模型与经典 HSV 空间的亮度模型相同，然后研究基于直接投影的 HSV 彩色模型向 RGB 的转换。形成完整的含色调、饱和度和亮度的彩色空间模型 (DHSV)。基于直接投影的 HSV 彩色模型克服了原 HSV 模型可扩展性不足的缺点。

(2) 基于直接投影 HSV 的光照增强方法对于弱光照增强任务而言，除了亮度通道外，另

外一个可供调整的分量是饱和度通道。不同光照水平的 RGB 图像经过转换成为彩色模型后，弱光照图片的饱和度通道像素平均值较正常光照图片大。对于同一场景下的弱光照图片和参考图片，如果仅对弱光照的亮度通道进行增强，饱和度通道保持不变，那么由于弱光照图片的饱和度通道像素平均值较正常光照图片大，增强后的图片会出现过饱和现象，色彩鲜艳程度超过参考图片，即明显的失真。本课题拟研究一种基于奇异值参数的饱和度抑制模型，模型能充分提取基于奇异值参数的光照不敏感特征，融合光照不敏感特征和饱和度信息，实现对饱和度通道像素强度自适应微调，保留饱和度通道的有效信息，产生接近于正常光照水平的饱和度通道。

极弱光照下，拍摄设备无法准确捕获场景中的颜色信息以及物体的纹理细节，导致图像亮度极低，严重的噪声和图像失真隐藏在黑暗中。对于极弱光照图像，如夜晚照明条件不足的监控图像，我们应该对其进行大幅度增强，同时尽量减少噪声等有害信息。由于 SVD 基可以表示不同频率的图片信息，奇异值则描述了对应 SVD 基的光照强度，为了实现对极弱光照图像良好的增强效果，本课题拟提出一种基于奇异值分解的亮度增强模型，基于弱光照图像特征差异进行奇异值分解，探索适合不同特征结构的奇异值分解方法，分析不同的子图像中的光照分布的特点，研究基于奇异值分解的小范围亮度增强模型和基于奇异值分解的大范围亮度增强模型。

第二章 相关背景知识介绍

第三章 基于 QRCP-DWT 的弱光照图像增强算法

3.1 引言

针对弱光照图像存在的整体亮度低，对比度差等问题，本章提出一种基于 QRCP-DWT 的图像增强算法。首先对图像的亮度通道进行离散小波变换，将得到的 LL 分量进行伽马校正，将校正后的图像用 QRCP 分解得到上三角矩阵的最大值，进而计算得到增强系数并获得新的上三角矩阵和增强后的 LL 分量。最后通过逆离散小波变换，输出图片的亮度和对比度都得到提升。

3.2 基于 QRCP-DWT 的弱光照图像增强算法

离散小波变换对数字图像进行二维分解变换，最终得到不同空间，不同频率的子图像。

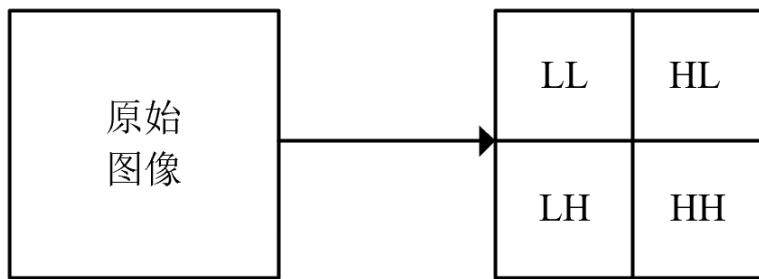


图 3.1 图像离散小波变换分解过程

二维离散小波变换 (2D Discrete Wavelet Transform, DWT) 可以用来分析和处理二维信号和图像。它的基本思想是通过使用小波函数对信号或图像进行分解，得到多个不同尺度和不同位置的分解系数，并使用这些分解系数来表示信号或图像。

在二维离散小波变换中，使用两个小波函数进行分解，一个小波函数用于水平方向的分解，另一个小波函数用于垂直方向的分解。下面是二维离散小波变换的数学公式：

小波变换后，生成了 LL, LH, HL, HH 四个分量，其中，LL 包含了绝大部分的光照信息，文献说明，调整 LL 分量可以调整图片的光照强度。

为了调整 LL 分量，本章提出一种基于 QRCP 系数的方法。对于一个矩阵 $f \in \mathbb{R}^{m \times n}, m \geq n$ ，QRCP 分解算法可表示为^[1]：

$$f = QRP \quad (3.1)$$

其中， $Q \in \mathbb{R}^{m \times m}$ 是正交矩阵， $R \in \mathbb{R}^{m \times n}$ 是上三角矩阵， $P \in \mathbb{R}_{c \times c}$ 是置换矩阵。式3.1的向量

表达形式为：

$$f = \sum_{i=1}^n (q_i r_i) P \quad (3.2)$$

其中， q_i 是正交列向量且满足 $\|q_i\|_2 = 1$ ($\|q_i\|_2$ 是 q_i 的二范数)，而 r_i 是对应的列向量。QRCP 基表示为：

$$B_i = \left(q_i \frac{r_i}{\|r_i\|_2} \right) P, \|r_i\|_2 \neq 0 \quad (3.3)$$

根据文献， $\|r_i\|_2$ 可以代表 QRCP 基的光照强度。增强表达式如下：

$$LL_e = \sum_{i=1}^n q_i (c * r_i) P \quad (3.4)$$

其中 c 代表增强系数。加入 c 后，QRCP 基的光照强度表示为 $\|cr_i\|_2 = c^2 \|r_i\|_2$ 。当 $c > 1$ 时，图像亮度提升；当 $c < 1$ 时，图像亮度降低。显然， c 应该根据弱光照图像自身亮度和目标亮度有关。本章中，将目标亮度设定为原图的 LL 分量经过伽马校正的结果，即

$$LL_t = LL^{\frac{1}{2.2}} \quad (3.5)$$

为了得到合适的增强系数 c ，分别对 LL 和 LL_t 作 QRCP 分解，得到各自的上三角矩阵

$$\begin{aligned} R &= [r_1, r_2, \dots, r_n] \\ R_t &= [t_1, t_2, \dots, t_n] \end{aligned} \quad (3.6)$$

由于 $\|r_i\|_2$ 和 $\|t_i\|_2$ 代表了 QRCP 基的光照强度，所以他们所在的向量的二范数可以代表整张图片的光照能量。即：

$$\begin{aligned} E &= \|\|r_1\|_2, \|r_2\|_2, \dots, \|r_n\|_2\|_2 \\ E_t &= \|\|t_1\|_2, \|t_2\|_2, \dots, \|t_n\|_2\|_2 \end{aligned} \quad (3.7)$$

其中， E, E_t 分别是 LL, LL_t 的光照能量。为了正确的构建增强系数，将来自 LL_t 的因子放在分子，而来自 LL 的因子放在分母：

$$c = \frac{\text{mean}(LL_t)}{\text{mean}(LL)} \frac{E_t}{E} \quad (3.8)$$

其中， $\text{mean}(\ast)$ 表示 \ast 的平均像素强度。算法整体流程图如3.2所示。输入图像首先经过离散小波分解，然后将分解得到的 LL 分量进行增强，最后经过逆离散小波变换得到增强后的 RGB 图片。

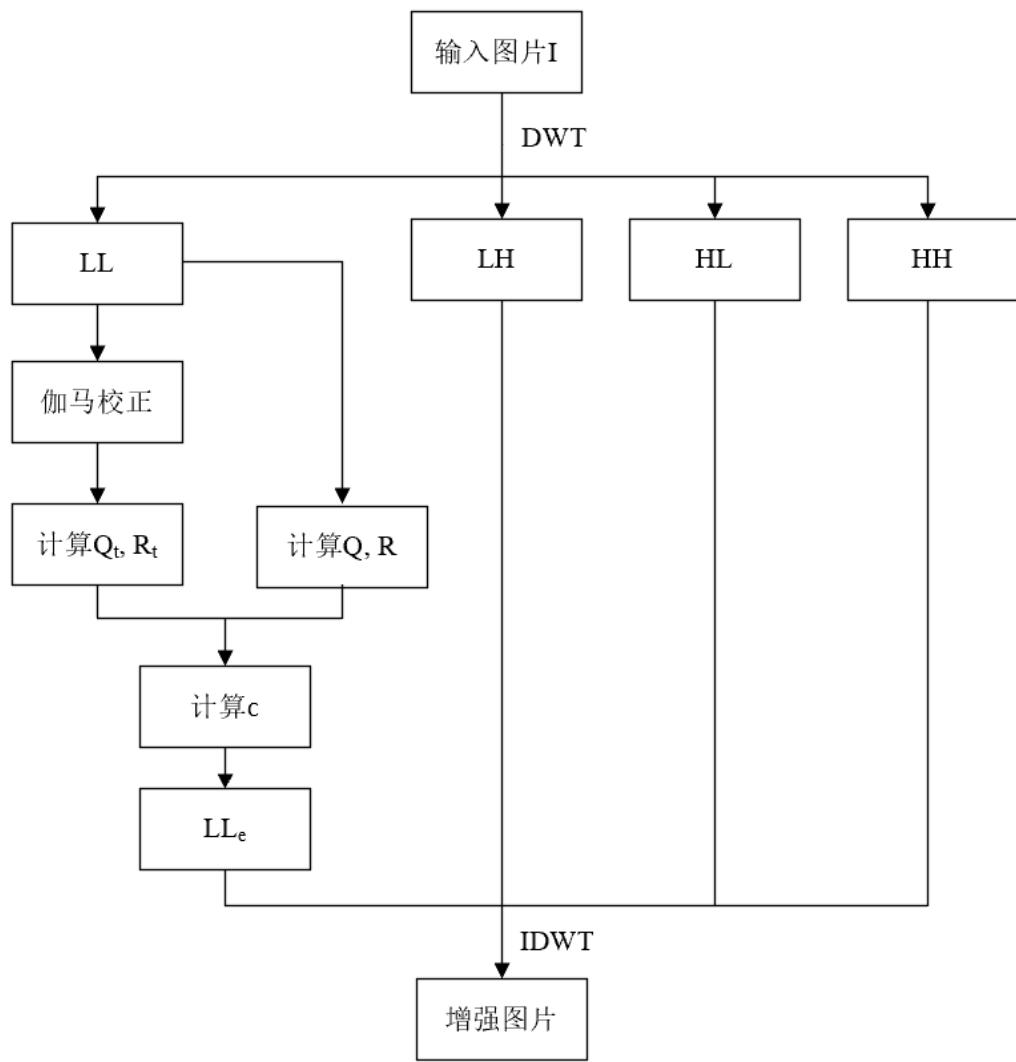


图 3.2 QRCP-DWT 算法流程图

3.3 实验

第四章 基于奇异值参数的弱光照图像增强算法

4.1 引言

针对弱光照图像增强问题，本章首先提出对弱光照图像亮度通道的对数图像进行奇异值分解，然后基于奇异值可用于描述对应 SVD 基的光照强度的假设，对奇异值进行归一化处理来对弱光照图片进行初步增强，并围绕奇异值引入参数实现不同范围的图像增强。本章内容首先对基于奇异值参数的亮度增强模型进行详细阐述，然后介绍本章使用的数据集、评价指标和对比算法，最后分析实验结果，证明算法的有效性。

4.2 基于奇异值参数的弱光照图像增强算法

4.2.1 奇异值增强模型

对于彩色图片，为了不破坏 RGB 三通道之间的关系，现有的图像增强方法^[2-4]往往选择将 RGB 图像转换到 HSV、HSI 等色彩空间，然后对亮度通道实现增强。本章采用 HSV 颜色空间，其亮度通道表达式为：

$$V = \max(R, G, B) \quad (4.1)$$

假设图片的亮度通道的对数版本为 f ，则有

$$f = \ln(V) \quad (4.2)$$

将其应用奇异值分解：

$$f = U D S^T \quad (4.3)$$

其中， $U = [u_1, u_2, \dots, u_n] \in R^{m \times n}$ 和 $S = [s_1, s_2, \dots, s_n] \in R^{n \times n}$ 是正交矩阵， $D \in R^{n \times n}$ 是对角矩阵，其对角元素 ($d_1 \geq d_2 \geq \dots \geq d_n$) 是 $\ln(V)$ 的奇异值。 $\ln(V)$ 的向量外积表达形式为：

$$f = \sum_{i=1}^n d_i u_i s_i^T \quad (4.4)$$

其中 $d_i u_i s_i^T$ 是第 i 个 SVD 子图像， $u_i s_i^T$ 是第 i 个 SVD 基。SVD 基可以表示不同频率的图片信息，奇异值则描述了对应 SVD 基的光照强度。基于这一条件，我们利用奇异值分解对弱光照图片进行增强。

从式 (4.4) 可知，第 i 张 SVD 子图像的光照强度为 $\|d_i u_i s_i^T\|_F^2 = d_i^2 \|u_i s_i^T\|_F^2 = d_i^2$ ，这表明奇异值可以反映 SVD 子图像的光照强度。由于 SVD 基的能量恒定 ($\|u_i s_i^T\|_F^2 = 1$)，且奇异

值 d_i 可视为 $u_i s_i^T$ 的系数，所以，我们可得出结论，SVD 基 $u_i s_i^T$ 反映了 f 不同频率的表面特征，且奇异值 d_i 可描述 SVD 基对应的光照强度。所以对奇异值进行处理可以实现对弱光照图像亮度通道增强。首先，按如下方式增大奇异值：

$$\delta_i = \begin{cases} d_i + \beta, & \text{if } \beta < d_i \\ d_i, & \text{if } \beta \geq d_i \end{cases} \quad (4.5)$$

其中， $\beta \geq 0$ 。弱光照图像中的噪声大部分集中在具有较小奇异值的 SVD 基中。为了防止放大这些噪声，式 4.5 保留了满足 $d_i < \beta$ 的值。

根据文献^[5]，对奇异值进行归一化，可以使单个图像的能量归一化：

$$f_n = \sum_{i=1}^n \frac{\delta_i}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} u_i s_i^T \quad (4.6)$$

其中， f_n 表示奇异值归一化后的对数图像，它的 F 范数表示为：

$$\begin{aligned} \|f_n\|_F &= \frac{\|f\|_F}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} \\ &= \frac{\sqrt{\text{tr}(f^T f)}}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} = \frac{\sqrt{\text{tr}((UDV^T)^T (UDV^T))}}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} \\ &= \frac{\sqrt{\text{tr}(D^2)}}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} = \frac{\sum_{i=1}^n \delta_i^2}{\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2} = 1 \end{aligned} \quad (4.7)$$

由于 F 范数表示矩阵奇异值的平方和，且奇异值可以描述光照强度，故任何光照水平的图片，经过式 (4.6) 奇异值归一化后，光照水平均相同，即实现了亮度增强。为了调节亮度通道，我们在对奇异值求单位二范数的基础上，采用了一个系数 α 来控制奇异值的归一化：

$$\eta_i = \frac{\delta_i}{(\|\delta_1, \dots, \delta_i, \dots, \delta_n\|_2)^\alpha} = \frac{\delta_i}{(\sum_{i=1}^n \delta_i^2)^{\frac{\alpha}{2}}} = \left(\sum_{i=1}^n \delta_i^2 \right)^{-\frac{\alpha}{2}} \delta_i = \zeta \delta_i \quad (4.8)$$

$$\Psi = U \delta_\eta S^T = \sum_{i=1}^n \eta_i u_i s_i^T = \sum_{i=1}^n \zeta \delta_i u_i s_i^T = \zeta \left(\sum_{i=1}^n \delta_i u_i s_i^T \right) = \zeta f \quad (4.9)$$

$$\exp(\Psi) = \exp(\zeta f) = \exp(f)^\zeta = V^\zeta \quad (4.10)$$

其中， $\alpha \geq 0$ ， $\zeta = (\sum_{i=1}^n \delta_i^2)^{-\frac{\alpha}{2}}$ ， $\delta_\eta \in R^{n \times n}$ 是对角线元素降序排列 ($\eta_1 \geq \eta_2 \geq \dots \geq \eta_n$) 的对角矩阵， $\exp(\Psi)$ 是 Ψ 的指数变换。式 (4.10) 的形式与伽马校正类似，但是不同于伽马校正通过像素操作直接提高图片的对比度，本章提出的 SVE 模型在对数域内将光照水平归一化，对应于像素域内将数据范围压缩至小区间，然后再将数据范围线性放大至 [0, 255] 来得到最终的增强结果。从数值上看，伽马校正系数的典型值为 1/2.2，而式 (4.10) 中的 ζ 值较小 (0.001-0.01)。

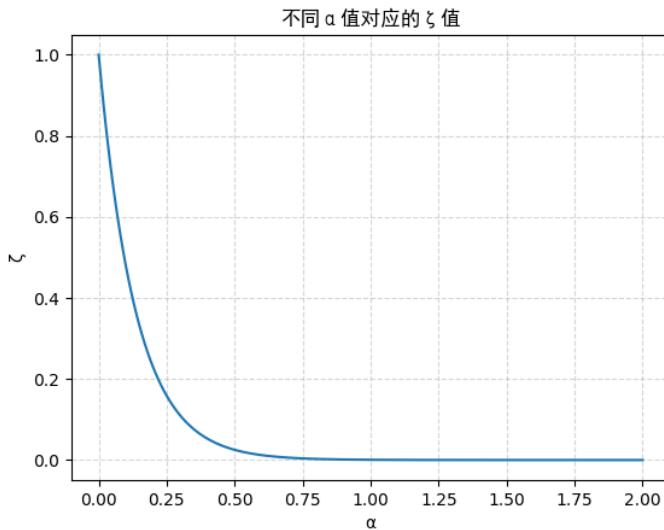
图 4.1 不同 α 值对应的 ζ 值图 4.2 不同 α 值的增强图片。从左到右: 原图、 $\alpha=0.01, 0.1, 0.2, 0.3, 0.4, 0.5, 0.8, 1.0$

图4.1展示了在 LOL 数据集上，不同 α 值对应的平均 ζ 值。容易看出， α 和 ζ 成反比：若 $\alpha = 0$ ，则 $\zeta = 1$ ， $\eta_i = delta_i$ ； $\alpha = 1$ ，则 $\Psi = f_n$ 。从上述可知， α 越接近于 0，增强图像亮度越低，越接近原始图像； $\alpha > 1$ 时， ζ 趋近于 0，式 (4.10) 难以将像素差异放大，图片无法正常输出。因此，本章将 α 的取值范围定为 $(0, 1]$ 。

图4.2为不同 α 值的增强效果。可以看出， $\alpha = 0.01$ 时，图片亮度几乎没有提升，随着 α 在 $[0.1, 0.5]$ 区间内增加，图像亮度也有明显提升，这同时与图4.1的规律相呼应。当 $\alpha > 0.5$ ，亮度基本保持在同一水平。从上述分析可知，当图片整体亮度较高时，应选用 $\alpha \in [0.1, 0.5]$ ，来防止过度增强；而当图片较暗时，应选用 $\alpha = 1$ 来充分点亮图片。

高质量图片往往拥有高对比度和分布均匀的直方图。虽然上述算法提升了图片亮度，但

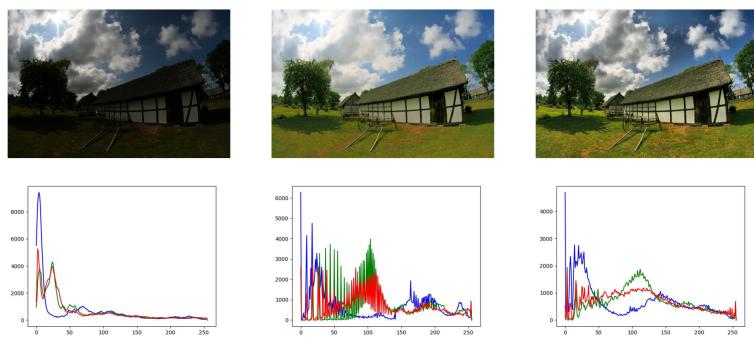


图 4.3 CLAHE 后处理措施的增强结果及其直方图

是增强图片的对比度不足，颜色信息不够丰富。为了提高 SVE 算法增强图片的对比度，本章提出加入限制对比度自适应直方图均衡化（Contrast Limited Adaptive Histogram Equalization, CLAHE）作为后处理措施。图4.3展示了 CLAHE 对增强结果的影响，第一列为原始图像，第二列为 SVE w/o CLAHE，第三列为 SVE。可以看出，SVE w/o CLAHE 虽然成功点亮图片，但是局部对比度不足，导致细节特征不清晰（如草地纹理）。加入 CLAHE 后，直方图曲线更平缓，且图片细节特征更丰富。

4.3 实验

4.3.1 数据库

本章实验用到的数据库有：LOL，Exdark 和 BDD。

LOL 数据库包含 500 对亮暗图片，其中 485 对被划分为训练集，其余 15 对组成测试集。绝大多数的暗图片是在固定其他参数不变的条件下，通过调整曝光时间和 ISO 拍摄而成的。LOL 数据库包含的图片场景有室内，校园，俱乐部，街道等。所有图片的大小均为 400×600 的 RGB 图片，格式为 PNG。

Exdark 数据库包含 7363 张弱光照图片，根据图像内容划分为自行车、船、瓶子、公交、轿车、猫、椅子、水杯、狗、摩托车、人类和椅子等 12 类。许多图片在背光、面对局部光源等条件下拍摄，增强难度较大。

BDD 数据库中的图片是用车载摄像头拍摄的，图片内容有夜晚或阴雨天气等光照条件不足的街景，居民区，高速路等。

4.3.2 评价指标和数据库设置

由于 Exdark 和 BDD 中的亮图片确实，故两个无参考指标 BRISQUE 和 NIQE 被用于衡量这两个数据库上的算法表现。BRISQUE 和 NIQE 值越小，增强图片的质量越好。另外，PSNR 和 SSIM 被用于 LOL 数据库的指标，PSNR/SSIM 越大，图像越接近于参考图像，即质量更高。

为了更好说明本章方法在不同亮度条件下的实际表现，本章将 Exdark 和 BDD 数据库按照图片的平均像素值各分为两个子集。已 Exdark 为例，平均像素值在 [0, 20) 的图片分入 ExD1，其余图片组成 ExD2，这样划分后，ExD1 和 ExD2 分别有 863 张和 1700 张图片。类似的，BDD1（平均像素值位于 [0, 20]）和 BDD2（平均像素值位于 [20, 50]）分别有 2353 张和 4941 张图片。

4.3.3 对比方法

- (1) 深度学习类方法: KinD+^[6], Zero-DCE^[7], EnlightenGAN^[8], RUAS^[9]。
(2) 基于数学模型方法: LIME^[3], CRM^[10], PIE^[11], SRIE^[12], GRI/GRIR^[5]。

本章中的对比方法均采用原作者推荐的默认参数。

4.3.4 实验结果

实验 1: LOL 数据库

表 4.1 LOL 测试集的平均 PSNR 和 SSIM 值

Approach	PSNR	SSIM
Retinex-Net	16.77	0.4621
Zero-DCE	15.92	0.4723
EnlightenGAN	17.48	0.5678
LightenNet	10.30	0.4021
PIE	15.92	0.5127
LIME	16.86	0.5950
CRM	17.45	0.5550
NPIE	16.76	0.5945
GRIR	16.73	0.5449
SVE	18.04	0.5952

表4.1列出了 LOL 测试集的平均 PSNR 和 SSIM 值。可以看出, SVE 的 PSNR 和 SSIM 值最高。

实验 2: ExDark

实验 3: BDD

表 4.2 ExDark 数据库实验结果

Approach	ExD1		ExD2	
	BRISQUE	NIQE	BRISQUE	NIQE
KinD+	35.0609	4.1200	27.8808	3.5875
Zero-DCE	36.8136	4.1305	27.3829	3.4585
EnlightenGAN	29.8545	3.4238	24.0108	3.1737
RUAS	38.8207	4.6782	30.8678	3.7348
PIE	39.3622	3.9233	30.3679	3.2245
LIME	41.0096	4.6863	31.4802	3.7004
CRM	38.5847	4.2207	27.3311	3.3599
SRIE	38.6066	4.0526	29.6901	3.2996
GRI	38.5401	4.2538	27.1667	3.3588
GRIR	37.8778	4.0842	27.1789	3.2554
SVE(1,0)	37.0533	4.0249	26.0177	3.2601
SVE(1,2)	27.3396	4.3188	23.8107	3.6077

表 4.3 BDD 数据集实验结果

Approach	BDD1		BDD2	
	BRISQUE	NIQE	BRISQUE	NIQE
KinD+	44.9937	3.9670	39.6926	3.6615
Zero-DCE	51.0236	4.8491	52.7232	4.5753
EnlightenGAN	39.5118	3.5593	38.1961	3.3048
RUAS	52.3714	4.9322	51.5203	4.7648
PIE	48.6722	4.1275	44.5003	3.6372
LIME	49.2632	4.4069	44.3307	3.7486
CRM	51.3524	4.3930	46.1548	3.6305
SRIE	49.6430	3.9987	44.0875	3.5246
GRI	51.3013	4.6411	50.3476	4.0298
GRIR	52.4184	4.7072	50.2277	4.1223
SVE(1,0)	49.7551	3.9509	42.3148	3.3615
SVE(1,2)	39.8074	3.9228	30.3562	3.3004

第五章 基于亮度先验的弱光照图像增强算法

5.1 引言

弱光照图像增强存在噪声严重、低对比度和颜色失真等问题。现有算法往往只在其中的某一个问题上取得效果，但很少能同时解决上述问题。本章提出一种基于亮度先验的重增强网络，将 QRCP-DWT 和 SVE 增强图片的 V 通道作为亮度先验知识与弱光照图片一同作为网络的输入，利用神经网络学习低质量图片到高质量图片的映射关系。最后的实验比较了算法与其他方法的各类指标，说明了本算法的优越性。

5.2 基于亮度先验的弱光照图像增强算法

5.2.1 QRCP-DWT 和 SVE 算法的局限性分析

在前两章提出的方法中，在 V 通道增强后，H 通道和 S 通道均不做处理，并直接与增强后的 V 通道一起转回了 RGB 格式图片。然而，以 LOL 数据集为例，增强后的 RGB 图片的亮度虽然得到改善，颜色信息和噪声水平却与其对应正常光照图片有较大差异。原因是，弱光照图像与其参考图像相比，不仅在光照水平上有差异（V 通道），而且在对比度和色调上（S 通道和 H 通道）也不相同。图5.1为 SVE 增强前后与参考图像在 HSV 空间的示意图。可以看出，H 通道和 S 通道在弱光照条件和正常光照条件下有显著不同，而且基于对 LOL 数据库其他亮暗图片对的观测可知，光照水平差距越大，这种差别就越显著。由于 H 通道和 S 通道代表了图片的颜色信息，所以 SVE 无法而且在颜色上与正常光照图片保持一致。另外，噪声在 H、S、V 通道上均存在，这就说明了如果在 V 通道增强后加入去噪步骤，并不能达到较好去噪效果。H 通道和 S 通道的这种差异是相机响应模型的非线性造成的，相机响应模型^[13] 可表示为：

$$P_c = f_c(E) \quad (5.1)$$

其中， P_c 为某一通道的像素值， f_c 表示非线性相机响应函数， E 为曝光度。上式说明，曝光度增加，图像越亮，但像素并非线性增加；另外，不同通道的相机响应函数也不相同。这两大因素共同导致像素的 (R, G, B) 向量在亮暗条件下的方向不一致，映射到 HSV 空间，即为 H 通道和 S 通道在不同曝光度图片上的差异。

基于上述分析，本章提出采取神经网络监督学习的方式，将用 QRCP-DWT 和 SVE 两种方法增强图片的 V 通道作为亮度先验，训练网络使其能够输出图像在某一亮度下的 H 通道和

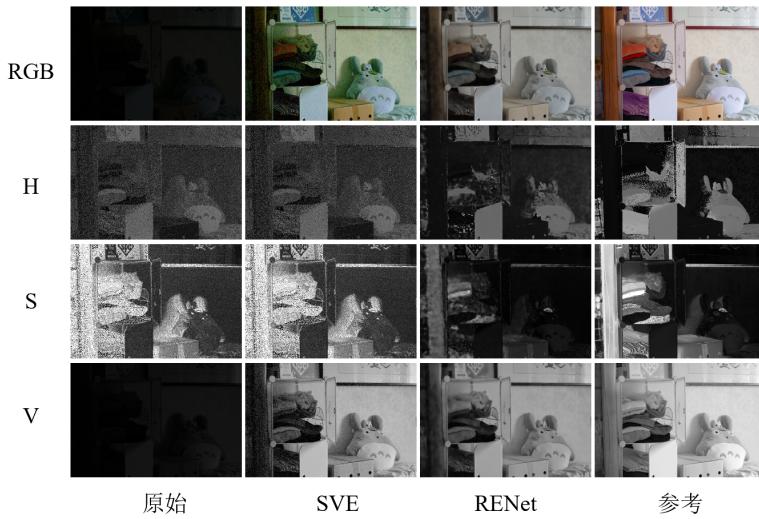


图 5.1 原图、SVE、RENet 参考图像在 RGB 和 HSV 空间的示意图

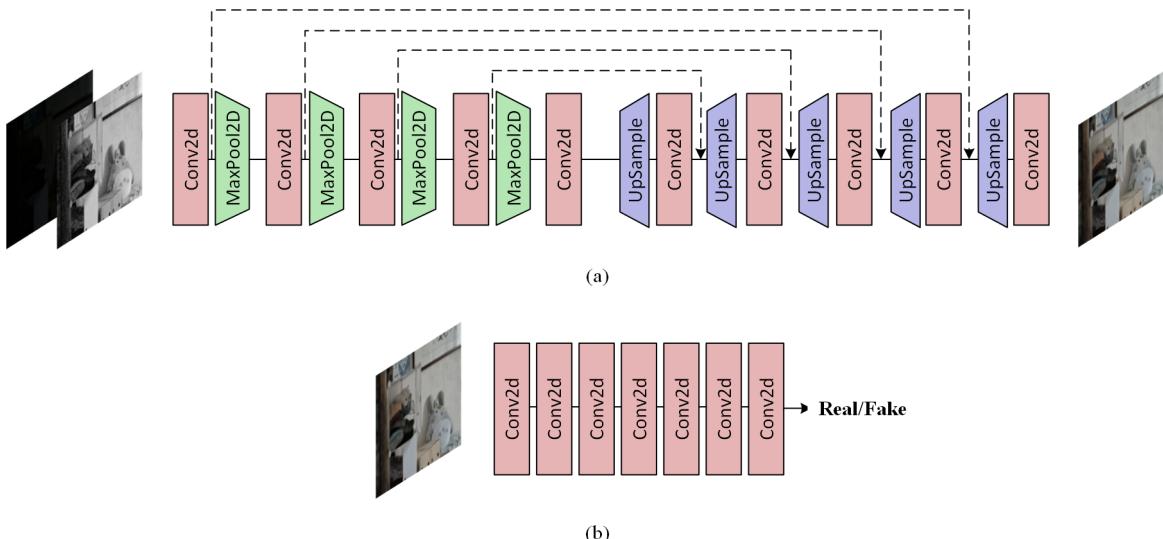


图 5.2 RENet 网络结构示意图。(a) 生成器。(b) 判别器

S 通道，即重增强网络（Re-Enhancement Network, RENet）。RENet 可作为 QRCP-DWT 和 SVE 的后处理措施，同时解决了噪声严重、颜色失真问题。

5.2.2 网络实现与损失函数

图5.2(a)展示了RENet的生成器结构。RENet的生成器基于U-Net搭建，在上采样和下采样之间采用跳线连接。引入判别器的原因是，生成对抗损失可以使网络增强图片更生动。

损失函数：

(1) L1 损失

$$L_1 = ||Y - \check{Y}||_1 \quad (5.2)$$

其中， Y 表示网络生成的增强图像， \check{Y} 表示参考图片。

(2) SSIM 损失

$$L_1 = SSIM(Y, \check{Y}) \quad (5.3)$$

(3) 对抗损失

$$L_{adv} = \sum_{n=1}^N -\log D(Y) \quad (5.4)$$

其中， $D(*)$ 表示鉴别器。

(4) 鉴别器损失

$$L_D = (D(I^N) - 1)^2 + (D(Y) - 0)^2 \quad (5.5)$$

其中， I^N 表示具备良好光照和高对比度的真实图片，且 I^N 与 X 非配对。

5.2.3 重增强网络与一般有监督网络的比较

RENet 的数学表达式为：

$$y = g(x, b) \quad (5.6)$$

其中， x 和 y 分别表示弱光照图像和增强图像， g 是增强网络， b 是亮度先验条件。而对于一般的有监督增强网络，没有了亮度先验条件，上式可写作：

$$y = g(x) \quad (5.7)$$

网络训练过程可以表示为接近下面的优化目标：

$$\operatorname{argmin}(\hat{y} - y) \quad (5.8)$$

其中， \hat{y} 为参考图像。上式说明，在不引入先验条件下，增强图像质量很难超越其参考图像。换句话说，参考图像很大程度上决定了增强图像质量。因此，为了达到良好的增强效果，普通的有监督网络必须光照条件良好的参考图像。但是，现实世界中参考图像的选择受到个人主观喜好和客观条件的强烈影响，很难确定最适合训练的参考图像。亮度先验决定了增强图片的亮度，使之不受参考图片亮度的影响。所以，RENet 对于训练图片选择的范围更广，提高了网络的潜力。

5.3 实验

第六章 总结与展望

参考文献

- [1] Hu C H, Lu X B, Liu P, et al. Single sample face recognition under varying illumination via qrcp decomposition [J]. IEEE Transactions on Image Processing, 2018, 28(5): 2624-2638.
- [2] Wang S, Luo G. Naturalness preserved image enhancement using a priori multi-layer lightness statistics [J]. IEEE transactions on image processing, 2017, 27(2): 938-948.
- [3] Guo X, Li Y, Ling H. Lime: Low-light image enhancement via illumination map estimation [J]. IEEE Transactions on image processing, 2016, 26(2): 982-993.
- [4] Fu X, Zeng D, Huang Y, et al. A weighted variational model for simultaneous reflectance and illumination estimation [C]//Proceedings of the IEEE conference on computer vision and pattern recognition. 2016: 2782-2790.
- [5] Hu C H, Yu J, Wu F, et al. Face illumination recovery for the deep learning feature under severe illumination variations [J]. Pattern Recognition, 2021, 111: 107724.
- [6] Zhang Y, Guo X, Ma J, et al. Beyond brightening low-light images [J]. International Journal of Computer Vision, 2021: 1-25.
- [7] Guo C, Li C, Guo J, et al. Zero-reference deep curve estimation for low-light image enhancement [C]// Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2020: 1780-1789.
- [8] Jiang Y, Gong X, Liu D, et al. Enlightengan: Deep light enhancement without paired supervision [J]. IEEE Transactions on Image Processing, 2021, 30: 2340-2349.
- [9] Liu R, Ma L, Zhang J, et al. Retinex-inspired unrolling with cooperative prior architecture search for low-light image enhancement [C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 10561-10570.
- [10] Ren Y, Ying Z, Li T H, et al. Lecarm: Low-light image enhancement using the camera response model [J]. IEEE Transactions on Circuits and Systems for Video Technology, 2018, 29(4): 968-981.
- [11] Fu X, Liao Y, Zeng D, et al. A probabilistic method for image enhancement with simultaneous illumination and reflectance estimation [J]. IEEE Transactions on Image Processing, 2015, 24: 4965-4977.
- [12] Fu X, Zeng D, Huang Y, et al. A weighted variational model for simultaneous reflectance and illumination estimation [J]. 2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016: 2782-2790.
- [13] Ying Z, Li G, Ren Y, et al. A new low-light image enhancement algorithm using camera response model [C]// Proceedings of the IEEE International Conference on Computer Vision Workshops. 2017: 3015-3022.

附录 1 攻读硕士学位期间撰写的论文

附录 2 攻读硕士学位期间申请的专利

附录3 攻读硕士学位期间参加的科研项目

致谢

 Lorem ipsum dolor sit amet, consectetur adipisicing elit,sed do eiusmod tempor incididunt ut labore et dolore magna aliqua. Ut enim ad minim veniam, quis nostrud exercitation ullamco laboris nisi ut aliquip ex ea commodo consequat. Duis aute irure dolor in reprehenderit in voluptate velit esse cillum dolore eu fugiat nulla pariatur. Excepteur sint occaecat cupidatat non proident, sunt in culpa qui officia deserunt mollit anim id est laborum.